

Zadanie č.4 (Dúhovky)

Klasifikácia príznakov

Autor: Bc. Viktor Chovanec

80331

Predmet: Biometria

BIOM



Obsah


Obsah.....	2
1 Úloha č. 1	3
2 Úloha č. 2	4
3 Bonus SIFT	6

1 Úloha č. 1

Prvým krokom pre splnenie zadania je výber korektných a nekorektných dvojíc zreničiek. Korektný pár je tvorený prvým obrázkom z oka daného jedinca, ku ktorému sú párované zostávajúce vzorky. Nekorektné údaje generujeme rovnako ako korektné, ale v druhom prvku je zmenené ľavé/pravé oko vzorky.

Nasledujúcim krokom je výpočet Hammingovej vzdialenosti medzi jednotlivými vzorkami. Použili sme vlastnú implementáciu tohto algoritmu, ktorý prechádza obe vzorky a porovnáva ich zhodu v hodnote pixelu. V prípade, že sú zhodné, alebo sa jeden z pixelov nachádza pod maskou, túto hodnotu ignorujeme. Inak sa výsledná Hammingová vzdialenosť zvýši o jedna.

Tento algoritmus následne aplikujeme na všetky možné otočenia obrázka, čím chceme dosiahnuť korektné natočenie oboch vzoriek. Správne natočenie indikuje minimálna hodnota tejto vzdialenosti. Rotácia obrázka prebieha prenesením posledného stĺpca obrázku na začiatok.




Z grafu je možné vidieť, že korektný pár má nižšiu hammingovu vzdialenosť ako obdobný pár so zlou dvojicou. Taktiež môžeme pozorovať, že nedokážeme jednoznačne rozoznať jednotlivé páry podľa ich vzdialenosti a preto to nie je vhodný údaj na klasifikáciu prvkov. Vhodným výstupom tejto metódy sú správne otočené vstupné dáta pre trénovanie neurónovej siete.

2 Úloha č. 2

Pre vypracovanie úlohy číslo 2 sme využili MLP neurónovú sieť. Ako vstupné dáta využívame výstup z prvej úlohy. Týmto procesom sme odstránili variácie pri natočení oka. Prekrytie zreničky sme riešili nulovaním pixelov nachádzajúcich sa pod viečkami.


Prvým krokom v spracovaní vstupných údajov je ich zmenšenie. Týmto procesom zabezpečíme menšie pamäťové a výpočtové nároky na tréning našej siete, pri minimálnej strate úspešnosti siete. MLP neurónová sieť v prostredí OpenCV vyžaduje ako vstupné vzorky vo vektorovej forme. Jeden riadok vstupnej matice predstavuje jednu vzorku. Vzorky sú následne vkladané ako riadky matice. Keďže sa jedná o druh učenia s učiteľom, je na vstupe vyžadovaná matica pravých zatriedení do skupiny. Taktiež sa jedná o maticu, kde riadok predstavuje vzorku zo vstupu. Jednotka na mieste niektorého stĺpca určuje zaradenie do skupiny popísanej poradovým číslom stĺpca.

Prvá tréningová skúška pozostávala zo 7 objektov, pričom na každého pripadali 2 tréningové a 1 testovací vstup




Úspešnosť na testovacích dátach stagnovala na hodnote 57%. Tento faktor si vysvetľujeme faktom nedostatočného počtu tréningových vzoriek jednotlivcov.

V druhom tréningu zvyšujeme počet objektov na 75, kde pre každého pripadajú 4 vstupné vzorky rozdelené na 3 tréningové a 1 testovacie.




Druhou úpravou bolo zvýšenie počtu tréovacích vzoriek pre jednotlivé objekty. Každý objekt obashoval 13 vzoriek; 9 tréovacích a 4 testovacie. Úspešnosť pre takéto rozloženie dát stúpila o ~6% na 76%.




3 Bonus SIFT

Cieľom úlohy bola extrakcia príznačov zreničiek pomocou algoritmu SIFT. Prvou zmenou oproti binarizovanej je fakt, že deskriptory extrahujeme z pôvodného vyrovnaného obrázku. Úvodným krokom je detekcia význačných bodov na obrázku. Z týchto bodov sa následne vypočítavajú deskriptory, ktoré popisujú daný obrázok. SIFT príznačky sú veľkosti 128 pixelov, pričom pri detekcii je možná zmena parametru výstupného počtu príznačných bodov. V prípade ich obmedzenia, algoritmus vracia daný počet najviac významných keypointov.



Všetky tieto deskriptory vkladáme do jedného vektoru, ktorý je následne vstupom pre tréning MLP neurónovej siete.



Najväčšiu úspešnosť sme dosiahli 36%.